SVEUČILIŠTE U ZAGREBU FAKULTET ORGANIZACIJE I INFORMATIKE V A R A Ž D I N

Ivan Vlašić

Analiza popularnosti glazbenih žanrova kroz vrijeme

PROJEKT IZ KOLEGIJA SKLADIŠTA PODATAKA I POSLOVNA INTELIGENCIJA

SVEUČILIŠTE U ZAGREBU FAKULTET ORGANIZACIJE I INFORMATIKE V A R A Ž D I N

Ivan Vlašić	
Matični broj:	
Studij: Baze podataka i baze znanja	
Analiza popularnosti glazbenih žanrov	va kroz vrijeme
,aa populariioon gia_boiiii _a.iiio	a mez viljeme
PROJEKT IZ KOLEGIJA SKLADIŠTA PODATAKA I POS	BLOVNA INTELIGENCIJA
Mentor/Mentori	
F	Prof. dr. sc. Kornelije Rabuzin

Izjava o izvornosti

Izjavljujem da je moj završni/diplomski rad izvorni rezultat mojeg rada te da se u izradi istoga nisam koristio drugim izvorima osim onima koji su u njemu navedeni. Za izradu rada su korištene etički prikladne i prihvatljive metode i tehnike rada.

Autor/Autorica potvrdio/potvrdila prihvaćanjem odredbi u sustavu FOI-radovi

Sadržaj

Sadržaj	iv
1. Uvod	1
2. Opis domene / procesa	2
3. Korištene tehnologije / alati	3
4. Opis korištenog skupa podataka	4
5. Model skladišta podataka (Star Schema)	5
6. ETL proces	6
6.1. Učitavanje izvornog skupa podataka	6
6.2. Kreiranje baze podataka	7
6.3. Izgradnja dimenzijskih tablica	8
6.4. Kreiranje činjenične tablice Song_Facts	11
6.5. Završetak ETL procesa	13
7. Izvještaji izrađeni u Power BI	13
8. Zaključak	17
Popis literature	18
Popis slika	19

1. Uvod

U ovom projektu izrađeno je skladište podataka koje sadrži informacije o pjesmama, izvođačima, žanrovima, datumu prikupljanja podataka i analitičkim činjenicama. Korišteni podaci su vezani uz glazbenu industriju.

Svrha projekta je omoguciti analizu glazbenih karakteristika poput plesnosti, energije, popularnosti i trajanja pjesama kroz različite dimenzije (žanr, država izvođača,tonalitet i datum).

2. Opis domene / procesa

Projekt se odnosi na analizu karakteristika glazbenih zapisa prikupljenih iz raznih izvora. Model skladišta podataka omogućava:

- Analizu popularnosti glazbenih žanrova kroz različite vremenske periode.
- Praćenje plesnosti (danceability) i energije (energy) pjesama kroz godine.
- Usporedbu različitih izvođača prema glazbenim karakteristikama poput akustičnosti, trajanja i glasnoće.
- Identfikaciju najpopularnijih pjesama te analizu prosječnog trajanja pjesama po žanrovima i ključevima (key).
- Podršku za daljnje poslovno odlučivanje i preporuke na temelju glazbenih trendova i ponašanja korisnika.

Svrha napravljenog skladišta je omogućiti brzo te jednostavn izvođenje složenih analiza na velikom skupu glazbenih podataka koristeći tehnike poslovne inteligencije.

3. Korištene tehnologije / alati

U sklopu izrade projekta korišteni su sljedeći alati:

MySQL Server

MySQL Server korišten je kao sustav za upravljanje bazama podataka (SUBP).[2]

• MySQL Workbench

MySQL Workbench korišten je za modeliranje baze podataka, kreiranje tablica, definiranje odnosa među entitetima,pisanje i izvršavanje SQL upita te vizualno upravljanje bazom. Uz pomoć ovog alata izrađena je struktura skladista podataka.[2]

• Power BI Desktop

Power BI Desktop korišten je za povezivanje na izrađeno skladište podataka i izradu vizualnih izvještaja. Alat je omogućio izradu interaktivnih grafova, prikaza i analiza temeljenih na podacima iz baze.[3]

4. Opis korištenog skupa podataka

Za potrebe izrade skladišta podataka i analize korišten je skup podataka vezan uz glazbenu industriju. Podaci uključuju informacije o pjesmama, izvođačima, žanrovima, popularnosti i raznim glazbenim karakteristikama poput plesnosti (danceability), energije (energy), akustičnosti (acousticness) i trajanja pjesama.

Izvor podataka:

Podaci su preuzeti s platforme Kaggle, iz skupa podataka pod nazivom *Prediction of Music Genre* [1]. Skup podataka ažuriran je prije tri godine.

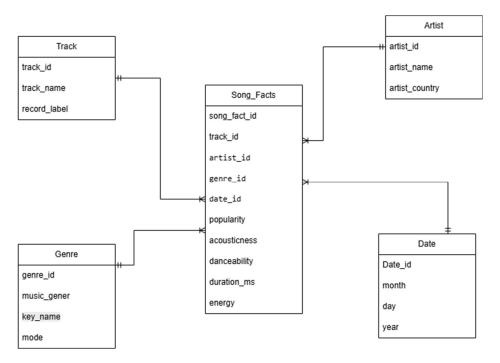
Struktura podataka:

Skup podataka obuhvaća sljedeće atribute:

- instance_id jedinstveni identifikator zapisa
- artist_name naziv izvođača
- track_name naziv pjesme
- popularity popularnost pjesme
- acousticness, danceability, energy, instrumentalness, speechiness, valence glazbene karakteristike izražene brojevima
- duration_ms trajanje pjesme u milisekundama
- **key, mode** glazbene tonalnosti pjesme
- **tempo** brzina pjesme izražena u BPM (beats per minute)
- loudness glasnoća pjesme izražena u decibelima
- obtained_date datum preuzimanja podataka
- music_genre žanr pjesme
- artist_country zemlja izvođača
- record_label diskografska kuća

5. Model skladišta podataka (Star Schema)

Na slici 1. ispod prikazan je zvjezdasti model (Star Schema) izrađen za potrebe analize glazbenih podataka:



Slika 1 Zvjezdasti model skladišta podataka za analizu glazbenih podataka

Opis modela:

Zvjezdast model temelji se na središnjoj tablici činjenica **Song_Facts**, koja sadrži ključne mjerne podatke za analizu karakteristika pjesama:

- popularity popularnost pjesme
- acousticness razina akustičnosti
- danceability -pogodnost pjesme za ples
- duration_ms trajanje pjesme u milisekundama
- energy energičnost pjesme

Tablica Song Facts povezana je s četiri dimenzijske tablice:

- Track: Sadrzi podatke o pjesmama (track id, track name, record label).
- Artist: Sadrži informacije o izvođačima (artist_id, artist_name, artist_country).
- **Genre**: Sadrži informacije o žanru i glazbenim karakteristikama pjesme (*genre_id, music_genre, key_name, mode*).
- **Date**: Sadrži vremenske podatke o preuzimanju pjesme (*date_id, day, month, year*).

Ključne značajke modela:

- Jednostavna struktura
- Fleksibilna analiza
- Optimalno za izvještavanje

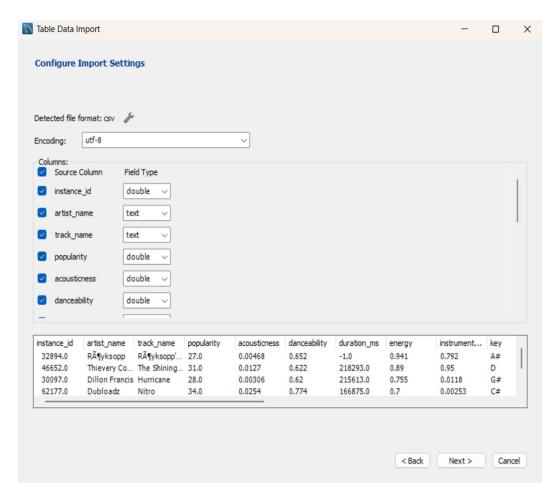
6. ETL proces

Za potrebe izrade skladišta podataka i analize korišten je skup podataka vezan uz glazbenu industriju. Podaci uključuju informacije o pjesmama, izvođačima, žanrovima, popularnosti i raznim glazbenim karakteristikama poput plesnosti (danceability), energije (energy), akustičnosti (acousticness) i trajanja pjesama.

ETL proces (Extract, Transform, Load) u sklopu ovog projekta obuhvatio je sljedeće korake:

6.1. Učitavanje izvornog skupa podataka

Izvorni skup podataka preuzet je sa stranice Kaggle u CSV formatu. Podaci su učitani u MySQL Workbench pomoću opcije Table Data Import Wizard, gdje su automatski smješteni u privremenu tablicu dataset. Potrebno je promjeniti za podatke povezane s datumima na datetime dok ostatak ostaje isto kao preporučeno. Vrijedi napomenuti da prvo je kreirana baza podatka (prikazano na slici 3) te je učitan izvorni skup podataka.



Slika 2 Učitavanje izvornog skupa podataka u MySQL bazu.

6.2. Kreiranje baze podataka

Kreirana je nova baza podataka pod nazivom glazba:

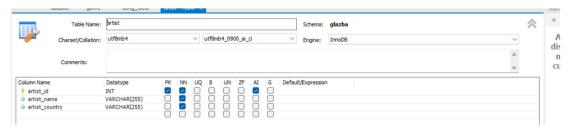
- 1 CREATE DATABASE glazba;
- 2 USE glazba;

Slika 3 Kreiranje baze podataka

6.3. Izgradnja dimenzijskih tablica

Za potrebe modeliiranja skladišta podataka izrađene su četiri dimenzijske tablice: Artist, Track, Genre i Date.

Slika 4 Prikaz kreiranja i umetanja podataka u tablicu



Slika 5 Prikaz postavki tablice

Ovaj SQL upit kreira tablicu "Artist" koja pohranjuje podatke o izvođacima, uključujući jedinstveno ID (artist_id), ime izvođača (artist_name) i zemlju izvođača (artist_country). Nakon toga, izvršava se unos podataka o izvođačima iz izvornog skupa podataka ("dataset"), gdje se izvođe jedinstveni parovi imena i zemlje izvođača.

```
14 • CREATE TABLE Track (

track_id INT AUTO_INCREMENT PRIMARY KEY,

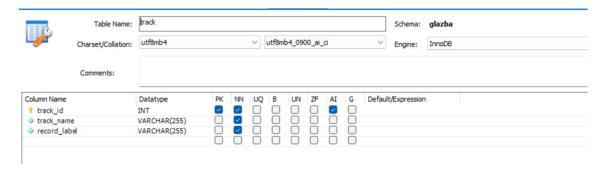
track_name VARCHAR(255),

record_label VARCHAR(255)

in serior into glazba.track (track_name, record_label)

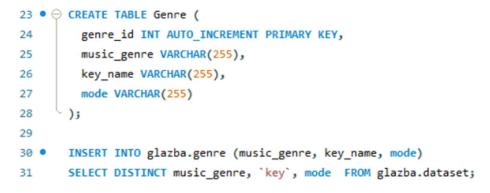
SELECT DISTINCT track_name, record_label FROM glazba.dataset;
```

Slika 6 Prikaz kreiranja i umetanja podataka u tablicu

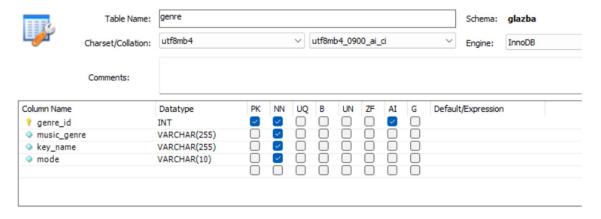


Slika 7 Prikaz postavki tablice

Ovaj SQL upit kreira tablicu "Track" koja pohranjuje podatke o pjesmama, uključujući jedinstveni ID pjesme (track_id), naziv pjesme (track_name) i izdavačku kuću (record_label). Nakon toga, izvršava se unos podataka o pjesmama iz izvornog skupa podataka ("dataset"), gdje se izvode jedinstveni parovi naziva pjesama i izdavačkih kuća.



Slika 8 Prikaz kreiranja i umetanja podataka u tablicu

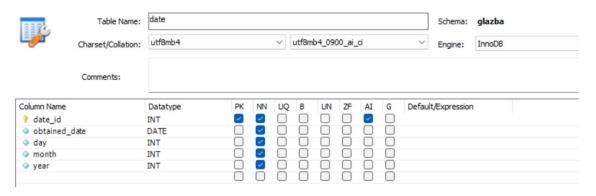


Slika 9 Prikaz postavki tablice

Ovaj SQL upit kreira tablicu "Genre" koja pohranjuje informacije o glazbenim žanrovima, tonalitetu (key_name) i načinu (mode) pjesme. Nakon toga, izvršava se unos podataka o žanrovima iz izvornog skupa podataka ("dataset"), gdje se izvode jedinstveni podaci o žanrovima, tonalitetu i načinu.

```
33 ● ○ CREATE TABLE Date (
         date id INT AUTO INCREMENT PRIMARY KEY,
34
35
         obtained date DATE,
36
         day INT,
37
         month INT,
38
         year INT
39
       );
40
41 •
       INSERT INTO glazba.date (obtained_date, day, month, year)
       SELECT DISTINCT
42
         obtained date,
43
         DAY(obtained_date),
44
45
         MONTH(obtained_date),
         YEAR(obtained_date)
46
       FROM glazba.dataset
47
       WHERE obtained_date IS NOT NULL;
48
49
```

Slika 10 Prikaz kreiranja i umetanja podataka u tablicu



Slika 11 Prikaz postavki tablice

Ovaj SQL upit kreira tablicu "Date" koja pohranjuje podatke o vremenskim dimenzijama, uključujući jedinstveni ID datuma (date_id), datum preuzimanja (obtained_date) te razdvojene atribute za dan (day), mjesec (month) i godinu (year). Nakon toga, izvršava se unos podataka o datumima iz izvornog skupa podataka ("dataset"), uz izvlačenje dana, mjeseca i godine iz datuma.

6.4. Kreiranje činjenične tablice Song_Facts

Kreirana je činjenična tablica Song_Facts koja povezuje sve dimenzije putem vanjskih ključeva i sadrži mjerne atribute poput popularnosti,plesnosti, akustičnosti, trajanja i energičnosti pjesama.

```
52 ● ☐ CREATE TABLE Song_Facts (
         song fact id INT AUTO INCREMENT PRIMARY KEY,
53
54
         track_id INT,
         artist id INT,
55
         genre_id INT,
56
         date_id INT,
57
         popularity INT,
58
59
         acousticness FLOAT,
60
         danceability FLOAT,
         duration_ms INT,
61
62
         energy FLOAT,
63
         FOREIGN KEY (track_id) REFERENCES Track(track_id),
         FOREIGN KEY (artist_id) REFERENCES Artist(artist_id),
64
         FOREIGN KEY (genre_id) REFERENCES Genre(genre_id),
         FOREIGN KEY (date_id) REFERENCES Date(date_id)
66
67
       );
```

Slika 12 Prikat kreiranja tablice

Podaci u tablicu **Song_Facts** učitani su kombiniranjem i spajanjem podataka iz svih dimenzija:

```
70 • 

INSERT INTO glazba.song_facts (
  71
             track_id,
  72
             artist_id,
  73
             genre_id,
  74
             date_id,
             popularity,
  75
  76
             acousticness,
  77
             danceability,
             duration_ms,
  78
  79
             energy
  80
         ( )
  81
          SELECT
  82
             t.track_id,
             a.artist_id,
  83
  84
             g.genre_id,
  85
             d.date_id,
             r.popularity,
  86
             r.acousticness,
  88
             r.danceability,
  89
            r.duration_ms,
  90
            r.energy
  91
          FROM glazba.dataset r
          JOIN glazba.track t
        ON r.track_name = t.track_name AND r.record_label = t.record_label
93
94
       JOIN glazba, artist a
95
        ON r.artist_name = a.artist_name AND r.artist_country = a.artist_country
96
       JOIN glazba.genre g
        ON r.music_genre = g.music_genre AND r.`key` = g.key_name AND r.mode = g.mode -- Dodano 'mode' join
97
       JOIN glazba.date d
99
        ON r.obtained_date = d.obtained_date;
100
```

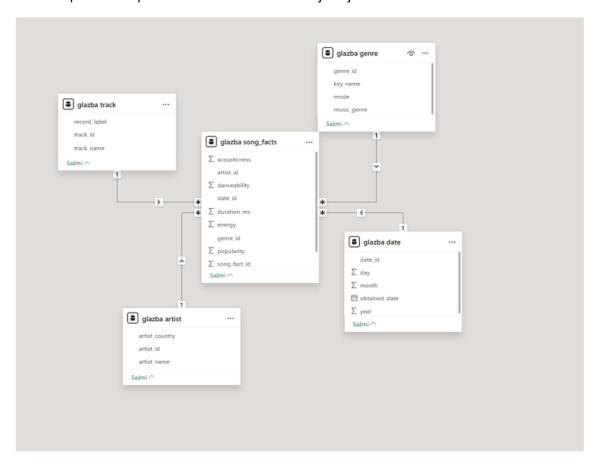
Slika 13 Prikaz unosa u tablicu

Ovaj SQL upit kreiira tablicu "Song_Facts" koja pohranjuje faktografske podatke o pjesmama. Tablica sadrži jedinstveni identifikator (song_fact_id), te poveznice na ostale dimenzijske tablice (Track, Artist, Genre, Date) kroz strane ključeve. Osim toga, tablica pohranjuje numeričke vrijednosti za popularnost pjesme (popularity), akustičnost (acousticness), plesnost (danceability), trajanje pjesme u milisekundama (duration_ms), i energičnost pjesme (energy). Strani ključevi omogućuju povezivanje s tablicma "Track","Artist","Genre" i "Date", čime se omogućava praćenje svih relevantnih dimenzija za svaku pjesmu.

- track_id,artist_id, genre_id, date_id: Poveznice na dimenzijske tablice koje omogućuju praćenje pjesme, izvođača, žanra i datuma.
- popularity, acousticness, danceability, duration_ms,energy: Numerički podaci o svojstvima pjesme koja omogućuju analizu kvalitete i karakteristika pjesme.

6.5. Završetak ETL procesa

Nakon izgradnje svih potrebnih tablica i učitavanja podataka, kreiran je funkcionalan model skladišta podataka spreman za analizu i izradu izvještaja u BI alatu Power BI.



Slika 14 Dodatni prikaz zvjezadanog modela u alatu MySQL Workbench

7. Izvještaji izrađeni u Power BI

Za izradu izvještaja korišten je Power BI Desktop, alat za vizualizaciju podataka koji omogućava kreiranje interaktivnih vizualizacija i analizu podataka na temelju unaprijed pripremljenog skladišta podataka. U ovom projektu izrađeno je nekoliko izvještaja koji pružaju uvid u različite aspekte glazbenih podataka,uključujući analizu žanrova, popularnosti pjesama, plesnosti, trajanja pjesama i drugih karakteristika.

Svaki izvještaj predstavlja zasebnu analizu podataka, gdje su korištene različite vrste vizualizacija, poput bar grafova, scatter plotova, linijskih grafikona i drugih vrsta prikaza koji

omogućuju detaljan uvid u obrasce i trendove unutar skupa podataka. U svim izvještajima korišteni su relevantni filtri i interaktivni elementi koji korisnicima omogućuju dublje istraživanje i usporedbu različitih metrika.

Za svakog od izvještaja prikazanih u sljedećim slikama, opisani su ključni uvidi, objašnjenje korištenih metrika i vizualnih elemenata,te značaj tih podataka u kontekstu analize glazbenih preferencija i karakteristika.

Popularnost glazbe glazbenih kuća 30 tis. 20 tis. 0 tis. Republic Columbia Universal Atlantic Records Music Records Glazbene kuće Records Glazbene kuće

Slika 15 Popularnost glazbe glazbenih kuća

Ovaj bar graf prikazuje ukupnu popularnost glazbe različitih glazbenih kuća. Najpopularnija je Republic Records, slijede Columbia Music i Universal Music,dok su Sony Music i Warner Music među manje popularnima unutar prikazanog uzorka. Popularnost je mjerena ukupnim brojem popularnosti pjesama pridruženih svakoj glazbenoj kući. Ovakva analiza omogućava usporedbu komercijalnog uspjeha različitih izdavača i prepoznavanje tržišnih lidera u glazbenoj industriji.



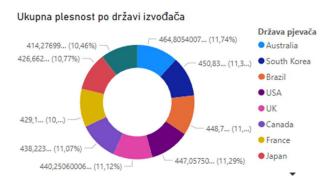
Slika 16 Prikaz prosječne energije glazbe po godinama

Linijski graf prikazuje promjene u prosječnoj energiji glazbe kroz vrijeme, počevši od 2010. godine. Vidljivo je da prosječna energija varira iz godine u godinu, s nekoliko vrhunaca oko 2017. i 2021. godine. Energija glazbe odnosi se na percepciju intenziteta i dinamike pjesama, a ova analiza pomaže u prepoznavanju trendova u stilu i produkciji glazbe tijekom posljednjeg desetljeća. Postoje teorije da je glazba 2016 bila vrhunac energične pop glazbe također isto za 2021 jer tijekom i nakon korone svijetu je bila potrebna više energična glazba te nam ovaj graf možda potvrđuje tu teoriju.



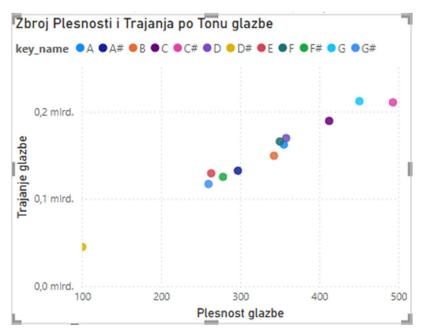
Slika 17 Ukupna popularnost po glazbeno,m žanru i modu

Ovaj bar graf prikazuje ukupnu popularnost različitih glazbenih žanrova, podijeljenu prema tonalitetu (mode: Major ili Minor). Najpopularniji žanr je Electronic, gdje dominira Major tonalitet, dok žanrovi Anime i Jazz imaju znatno manju ukupnu popularnost. Analiza tonaliteta pomaže razumjeti emocionalne karakteristike popularne glazbe,pri čemu Major tonaliteti često odražavaju pozitivniju i energičniju atmosferu.



Slika 18 Ukupna plesnost po državi izvođača

Prikazani prstenasti (donut)graf ilustrira ukupnu plesnost glazbe prema zemlji porijekla izvođača. Vrijednosti su relativno ravnomjerno raspoređene među državama, s blagim varijacijama, što pokazuje da plesnost nije izrazito vezana uz određene geografske regije. Ovaj graf omogućava uvid u to kako karakteristike ritma i plesne energije variraju među izvođačima različitih država.



Slika 19 Prikaz zbroja plesnosti i trajanja po tonu glazbe

Scatter plot prikazuje odnos plesnosti i trajanja pjesama prema tonalitetu (key_name). Vidljiva je pozitivna povezanost a to je da pjesme s većom plesnošću često imaju duže trajanje.

Boje označavaju različite tonalitete, a analiza pokazuje da se neki tonovi (npr. C# i G) češće pojavljuju u segmentima s višom plesnošću.

Analiza glazbenih podataka kroz različite vizualizacije pokazuje nekoliko intrigantnih uvida. Na primjer, vidimo da popularnost glazbe snažno varira između različitih glazbenih kuća, s liderima poput Republic Records, dok su žanrovi poput Elektroničke glazbe dominantni u Major tonalitetu, što sugerira da energičniji žanrovi često odražavaju pozitivniji ton. Također, postoji zanimljiva povezanost između plesnosti i trajanja pjsama - duže pjesme s većom plesnošću sugeriraju da energičniji tonovi često zahtijevaju i duži vremenski okvir za izražavanje svoje dinamike. Ovi uvidi mogu pružiti dublje razumijevanje kako različiti glazbeni faktori utječu na preferencije publike i oblikuju industrijske trendove.

8. Zaključak

Kroz ovaj projekt razvijen je sustav skladišta podataka temeljen na MySQL-u koji omogućava analizu glazbenih podataka s različitih aspekata, od popularnosti i plesnosti do tonaliteta i trajanja pjesama. Korištenjem Power Bl-a,kreirani su izvještaji koji vizualiziraju te podatke, pružajući uvid u trendove i povezanosti unutar glazbene industrije na lakši način. Projekt je demonstrirao kako se različite tehnologije i alati mogu koristiti zajedno za učinkovitu analizu velikih skupova podataka, te kako vizualizacije mogu pomoći u razumijevanju kompleksnih obrazaca s velikim skupom podatka koji oblikuju globalne glazbene preferencije. Kroz ovu analizu postignuta je dublja spoznaja o glazbenim žanrovima, popularnosti izvođaca i promjenama u energetskoj dinamici glazbe kroz vrijeme.

Popis literature

- [1] Vicsuperman. (26.4.2025). *Prediction of Music Genre*. Kaggle. Preuzeto 2025., s https://www.kaggle.com/datasets/vicsuperman/prediction-of-music-genre
- [2] MySQL Documentation. (26.4.2025). *MySQL 8.0 Reference Manual*. Oracle. Preuzeto 2025., s https://dev.mysql.com/doc/
- [3] Microsoft. (26.4.2025). *Power BI Documentation*. Microsoft Docs. Preuzeto 2025., s https://learn.microsoft.com/en-us/power-bi/

Popis slika

Slika 1 Zvjezdasti model skladišta podataka za analizu glazbenih podataka	5
Slika 2 Učitavanje izvornog skupa podataka u MySQL bazu	7
Slika 3 Kreiranje baze podataka	7
Slika 4 Prikaz kreiranja i umetanja podataka u tablicu	8
Slika 5 Prikaz postavki tablice	8
Slika 6 Prikaz kreiranja i umetanja podataka u tablicu	8
Slika 7 Prikaz postavki tablice	9
Slika 8 Prikaz kreiranja i umetanja podataka u tablicu	9
Slika 9 Prikaz postavki tablice	9
Slika 10 Prikaz kreiranja i umetanja podataka u tablicu	10
Slika 11 Prikaz postavki tablice	10
Slika 12 Prikat kreiranja tablice	11
Slika 13 Prikaz unosa u tablicu	12
Slika 14 Dodatni prikaz zvjezadanog modela u alatu MySQL Workbench	13
Slika 15 Popularnost glazbe glazbenih kuća	14
Slika 16 Prikaz prosječne energije glazbe po godinama	14
Slika 17 Ukupna popularnost po glazbeno,m žanru i modu	15
Slika 18 Ukupna plesnost po državi izvođača	15
Slika 19 Prikaz zbroja plesnosti i trajanja po tonu glazbe	16